

Trabajo Practico Final

Mineria y Modelizado de Datos

Segmentacion de Clientes y Analisis de Canasta
en una Tienda de Articulos del Hogar

Materia:	Mineria y Modelizado de Datos
Algoritmos:	K-Means (segmentacion de clientes) + APRIORI (reglas de asociacion)
Dataset:	online_retail_hogar.csv (datos sinteticos, tienda argentina)
Registros:	9.363 transacciones 400 clientes 40 productos
Periodo:	Junio 2023 - Diciembre 2024
Moneda:	Pesos Argentinos (ARS)
Grupo:	3 a 4 integrantes (completar nombres)
Cuatrimestre:	1er Cuatrimestre 2026

Buenos Aires, junio de 2026

1. Introduccion

1.1 Contexto y motivacion

El presente trabajo practico final corresponde a la materia Minería y Modelizado de Datos del IFTS N° 24. El objetivo es aplicar técnicas de minería de datos sobre un conjunto de datos transaccionales, siguiendo la metodología CRISP-DM, y extraer conocimiento accionable para la toma de decisiones empresariales.

El caso de negocio es una tienda argentina de artículos del hogar que comercializa velas, accesorios de cocina, decoración, aromatización y regalería. La empresa dispone de datos históricos de 2.790 facturas emitidas a 400 clientes entre junio 2023 y diciembre 2024, con precios expresados en pesos argentinos.

1.2 Problematica de negocio

- Problema 1:** Todos los clientes reciben el mismo trato sin considerar su historial de compras, generando ineficiencia en el gasto de marketing.
- Problema 2:** La empresa no sabe que productos tienden a comprarse juntos, perdiendo oportunidades de promociones cruzadas.

1.3 Preguntas de investigacion

1. Como podemos agrupar clientes segun su comportamiento de compra?
2. Que productos se compran juntos con mayor frecuencia?
3. Que acciones concretas puede tomar la empresa a partir de estos hallazgos?

1.4 Dataset utilizado

Se utiliza **online_retail_hogar.csv**, dataset sintético con patrones de compra realistas. El TP permite el uso de datos simulados o reales (según la pauta). Todos los importes están expresados en pesos argentinos (ARS).

Columna	Tipo	Descripcion
NroFactura	String	Identificador unico de la factura
IDCliente	String	Identificador unico del cliente
Descripcion	String	Nombre del producto
Categoria	String	Categoria del producto
Cantidad	Entero	Unidades compradas
PrecioUnitario	Float	Precio unitario en ARS
PrecioTotal	Float	Cantidad x PrecioUnitario (ARS)
FechaFactura	Fecha	Fecha de la transaccion
Ciudad	String	Ciudad del cliente

2. Metodologia

El proyecto sigue la metodologia **CRISP-DM**, estandar ampliamente utilizado en proyectos de mineria de datos:

Fase CRISP-DM	Aplicacion en este proyecto
1. Comprension del negocio	Definicion del caso, problemas y objetivos
2. Comprension de los datos	EDA: distribucion de variables, estadisticas descriptivas
3. Preparacion de datos	Calculo de variables por cliente, estandarizacion, matriz de canasta
4. Modelado	K-Means (K=4) sobre variables de comportamiento + APRIORI (min_support=2%)
5. Evaluacion	Silhouette Score, Metodo del Codo, analisis de Lift y Confianza
6. Despliegue	Recomendaciones accionables para el area comercial

2.1 Algoritmo K-Means — Segmentacion de clientes

K-Means es un algoritmo de clustering no supervisado que agrupa datos minimizando la distancia euclidiana entre cada punto y el centroide de su cluster. Como se detalla en el apunte de la materia, el algoritmo itera:

1. Inicializar K centroides (k-means++ para distribucion inteligente).
2. Asignar cada cliente al centroide mas cercano.
3. Recalcular cada centroide como promedio de sus puntos asignados.
4. Repetir hasta convergencia o hasta alcanzar max_iter.

Para aplicar el algoritmo calculamos tres variables numericas por cliente:

Variable	Definicion	Interpretacion
DiasDesdeUltimaCompra	Dias entre la ultima factura y la fecha de referencia	Mayor = cliente mas activo
Frecuencia	Numero de facturas distintas en el periodo	Mayor = cliente mas fiel
MontoTotal	Suma de PrecioTotal de todas sus compras	Mayor (ARS) = cliente mas valioso

Como indica el apunte (seccion Escalado de Datos), las tres variables tienen escalas muy distintas y es obligatorio estandarizarlas con StandardScaler antes de aplicar K-Means.

2.2 Algoritmo APRIORI — Reglas de Asociacion

Fase 1: identificar itemsets (combinaciones de productos) que superen el umbral min_support.

Fase 2: generar reglas A -> B evaluadas por Soporte, Confianza y Lift.

Metrica	Formula	Interpretacion
Soporte	$P(A \cap B)$	Frecuencia del itemset en el total de transacciones
Confianza	$P(B A) = P(A \cap B) / P(A)$	Probabilidad de comprar B si ya se compro A
Lift	$Confianza / P(B)$	Lift > 1 indica asociacion real, no aleatoria
Conviction	$(1 - P(B)) / (1 - Confianza)$	Mayor valor = regla mas determinista

3. Modelado

3.1 Exploracion de los datos (EDA)

El dataset cuenta con 9.363 registros sin valores nulos ni duplicados. Los precios estan expresados en pesos argentinos. La categoria Regaleria lidera en ingresos totales, seguida por Decoracion y Aromatizacion.

Exploración inicial del dataset




Figura: EDA: distribucion de variables y ventas por categoria




Figura: Evolucion mensual de ventas (ARS)

3.2 Seleccion del K optimo

Se evaluaron valores de K de 2 a 10 usando los dos metodos explicados en el apunte:

Metodo del Codo: la reduccion de inercia se vuelve menos pronunciada a partir de K=4.

Silhouette Score: el valor maximo se alcanza en K=4 (score: 0.4854).




Figura: Metodo del Codo y Silhouette Score — K=4 optimo

Hiperparametro	Valor	Justificacion
n_clusters	4	Silhouette Score maximo (0.4854) y quiebre en el metodo del codo
init	k-means++	Centroides iniciales bien distribuidos, menor riesgo de minimos locales
n_init	10	Ejecuta 10 veces, retiene la solucion con menor inercia
max_iter	300	Limite de iteraciones, suficiente para convergencia
random_state	42	Semilla fija para garantizar reproducibilidad del experimento

3.3 Segmentos identificados

Distribución de variables de comportamiento por Cluster




Figura: Variables de comportamiento por cluster




Figura: Proyeccion 2D con PCA — separacion de los 4 clusters

Cluster	Perfil	N	%	Dias ult.compra	Frecuencia	Monto total (A)
0	Clientes en Riesgo / Dormidos	93	23.2%	280	2.0	\$207.637
1	Clientes Activos Frecuentes	80	20.0%	41	13.0	\$1.397.884
2	Clientes VIP	29	7.3%	21	24.0	\$2.679.476
3	Clientes Ocasionales	198	49.5%	94	4.0	\$482.848

Silhouette Score: 0.4854 | Inercia: 197.8 | Convergencia en 5 iteraciones.

3.4 Modelado APRIORI

Hiperparametro	Valor	Justificacion
min_support	0.02 (2%)	Itemsets presentes en al menos el 2% de las 2.790 facturas.
max_len	4	Maximo 4 productos por itemset para mantener reglas interpretables.
metric	lift	Priorizamos reglas con asociacion real (lift > azar).
min_threshold	1.2	La co-compra es al menos un 20% mas probable que al azar.

Resultado: **67 itemsets frecuentes** y **70 reglas de asociacion** con Lift > 1.2.




Figura: Top 20 itemsets frecuentes por soporte




Figura: Heatmap de Lift entre productos

#	Antecedente	Consecuente	Soporte	Confianza	Lift
1	Bolsa Regalo Pequeña	Papel Tissue + Tarjeta Saludo	~3%	~27%	11.86
2	Papel Tissue + Tarjeta Saludo	Bolsa Regalo Pequeña	~3%	~82%	~11
3	Bolsa Regalo Peq + Papel Tissue	Tarjeta Saludo	~3%	~76%	~10

4	Papel Tissue + Lazo Decorativo	Bolsa Regalo Grande	~4%	~86%	~9
5	Difusor Cana	Esencia Rosa o Jazmin	~3%	~70%	~7




Figura: Confianza vs Lift por regla

4. Resultados

4.1 K-Means

Metrica	Valor	Interpretacion
Silhouette Score	0.4854	Separacion aceptable entre clusters (rango -1 a 1)
Inercia	197.8	Suma de distancias cuadradas intra-cluster
Iteraciones	5	Convergencia muy rapida
K elegido	4	Optimo por Silhouette Score y metodo del codo

Segmentación K-Means: clientes vs ingresos




Figura: Distribucion de clientes e ingresos por segmento

Los **Clientes VIP** (7.3%) concentran el mayor monto total de compras a pesar de ser el grupo mas reducido. Los **Clientes en Riesgo** (23.2%) no compran desde hace en promedio 280 dias.

4.2 APRIORI

Los articulos de **regaleria** presentan los Lift mas altos (hasta 11.86): los clientes arman kits completos de regalo en una sola compra.

El **Difusor de Cana** y las esencias tienen fuerte asociacion porque el difusor no funciona sin la esencia.

Las **velas aromaticas** se compran habitualmente junto con el portavelas.

5. Conclusiones y Recomendaciones

5.1 Recomendaciones de negocio

Recomendacion 1: Marketing diferenciado por segmento

Cientes VIP (n=29): Programa de puntos premium, acceso anticipado a nuevos productos. Son el activo mas valioso de la empresa.

Cientes Activos Frecuentes (n=80): Descuentos por volumen, tarjeta de fidelidad. Candidatos naturales a VIP.

Cientes Ocasionales (n=198): Campanas de email con ofertas de tiempo limitado para aumentar la frecuencia.

Cientes en Riesgo (n=93): Cupon de reactivacion con 15% de descuento y mensaje personalizado.

Recomendacion 2: Bundles y cross-selling basados en APRIORI

Kits de regalo: Armar packs listos (Bolsa + Papel Tissue + Tarjeta + Lazo). Lift de 11.86 confirma que la combinacion no es aleatoria.

Sugerencias en tienda online: Al agregar una Vela al carrito, sugerir el Portavelas con 10% de descuento. Al comprar Difusor, sugerir las Esencias.

Layout de la tienda fisica: Ubicar productos con alto Lift de forma contigua para incentivar la compra por impulso.

5.2 Conclusiones generales

K-Means segmentó los 400 clientes en 4 grupos usando variables de comportamiento de compra. Un Silhouette Score de 0.4854 valida la calidad de la segmentación. La reducción de 9.363 transacciones a 4 perfiles claros permite estrategias de marketing eficientes y personalizadas.

APRIORI descubrió 67 itemsets frecuentes y 70 reglas con patrones coherentes con el dominio del negocio (tienda de decoración y regalos). Los valores de Lift superiores a 10 en la categoría regalería son directamente accionables.

Ambas técnicas brindan una visión complementaria: **como se comportan los clientes** (K-Means) y **que compran juntos** (APRIORI).

5.3 Trabajo futuro

Se sugiere: (1) explorar DBSCAN para detectar clientes anómalos sin necesidad de especificar K; (2) incorporar datos de devolución y descuentos; (3) automatizar el pipeline mensualmente para detectar cambios de segmento en tiempo real.

Referencias

- Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. VLDB Conference.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. 5th Berkeley Symposium.
- Chapman, P. et al. (2000). CRISP-DM 1.0 Step-by-step data mining guide. SPSS Inc.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825-2830.
- Rasanen, R. (2020). mlxtend: Machine learning extensions for Python. v0.18.0.
- IFTS N° 24 (2026). Apuntes de la materia Minería y Modelizado de Datos. Unidades 1, 2, 8.